

Anàlisi d'espais de representació profunds pel diagnòstic del carcinoma colorectal en histopatologia digital

Pau Martí Escolà

Resum— Aquest projecte se centra en l'anàlisi d'espais de representació profunds per al diagnòstic del carcinoma colorectal pT1 en histopatologia digital. Donada la complexitat de la detecció d'aquest càncer en etapes primerenques a causa de canvis morfològics subtils, s'explora l'aplicació de xarxes neuronals, especialment els *Vision Transformers* (ViTs), les *Graph Neural Networks* (GNNs) i la combinació d'aquests dos. La metodologia inclou la preparació i anàlisi de dades histopatològiques, dividint les imatges en *patches* i classificant-les segons el percentatge d'infiltració tumoral. S'implementen i comparen models de *deep learning* existents com CNNs, ResNet, DenseNet i ViTs, incloent-ne un preentrenat específicament en histopatologia. Un aspecte clau del projecte és el desenvolupament d'arquitectures híbrides, combinant l'extracció de característiques i matrius d'atenció dels ViTs amb *Neural Networks* (NN) o GNNs per una representació més estructurada del teixit. S'experimenta amb diferents estratègies d'agregació de les 12 matrius d'atenció del ViT, incloent la mitjana ponderada, una capa d'agregació Conv2D entrenada i l'ensemble de 12 models mitjançant *max voting*. Hem pogut demostrar que les arquitectures híbrides utilitzant el ViT com a extractor de característiques són millors que les tradicionals. La millor arquitectura ha sigut ViT+NN amb una AUC de 0.9537 ± 0.0771 .

Paraules clau— Histopatologia digital, Carcinoma colorectal, Aprenentatge profund, *Vision Transformers* (ViTs), *Graph Neural Networks* (GNNs), Detecció d'infiltracions, Agregació, Arquitectura Híbrida, Atenció.

Abstract— This project focuses on the analysis of deep representation spaces for the diagnosis of pT1 colorectal carcinoma in digital histopathology. Given the complexity of detecting this early-stage cancer due to subtle morphological changes, the application of neural networks is explored, particularly Vision Transformers (ViTs), Graph Neural Networks (GNNs), and the combination of these two. The methodology includes the preparation and analysis of histopathological data, dividing images into patches and classifying them according to the percentage of tumor infiltration. Existing deep learning models such as CNNs, ResNet, DenseNet, and ViTs are implemented and compared, including one pre-trained specifically on histopathology. A key aspect of the project is the development of hybrid architectures, combining feature extraction from ViTs with NNs or GNNs (GCN and GAT). Different strategies for aggregating the 12 attention matrices of the ViT are experimented with, including weighted averaging, a trained Conv2D aggregation layer, and the ensemble of 12 models through max voting. We have demonstrated that hybrid architectures using the ViT as a feature extractor outperform traditional architectures. The best-performing model was ViT+NN, achieving an AUC of 0.9537 ± 0.0771 .

Index Terms— Digital Histopathology, Colorectal Carcinoma, Deep Learning, Vision Transformers (ViTs), Graph Neural Networks (GNNs), Infiltration Detection, Aggregation, Hybrid Architecture, Attention.

1 INTRODUCCIÓ

El càncer colorectal és el tercer càncer més comú a nivell global, amb 1.85 milió de casos anualment. A Espanya,

40203 casos de càncer colorectal van ser diagnosticats al 2023, sent gairebé el 15% de tots els tumors diagnosticats. Aquest càncer és el que es diagnostica amb més freqüència i la segona causa de mort cancerígena més comuna. [19]

-
- E-mail de contacte: maespau03@gmail.com
 - Menció realitzada: Computació
 - Treball tutoritzat per: Carles Sánchez (*Interactive and Augmented Modelling CVC*)
 - Curs 2024/25

El carcinoma colorectal pT1 és una forma primerenca del càncer colorectal que es caracteritza per l'única invasió de la submucosa intestinal, sense arribar a afectar cap capa més profunda de la paret intestinal. Tot i ser una etapa

inicial, la detecció precisa i el diagnòstic adequat de les lesions pT1 són crucials per a la intervenció precoç i la millora de les taxes de supervivència. No obstant això, la identificació d'aquest tipus de carcinoma a través d'imatges histopatològiques continua sent un desafiament per als patòlegs, ja que els canvis morfològics associats són sovint subtils i difícils de distingir, la qual cosa pot afectar la capacitat de proporcionar un diagnòstic adequat i oportú, a més a més de requerir una gran quantitat de temps.

Des del Centre de Visió per Computador (CVC) i dins del grup de recerca *Interactive Modelling Augmentation* (IAM) s'ha iniciat una col·laboració amb l'hospital Josep Carreres per a la detecció digital de pT1 mitjançant eines d'aprenentatge profund. Davant d'aquest problema, l'aplicació de xarxes neuronals basades en atenció per a l'anàlisi d'imatges biomèdiques ha guanyat una gran rellevància en els darrers anys, especialment en l'àmbit de la patologia digital. Els *Vision Transformers* (ViTs) han demostrat una capacitat excepcional per captar patrons espacials complexos en imatges histopatològiques, fet que els fa ideals per a tasques de classificació i detecció d'anomalies [4]. Una extensió que podria ser especialment prometedora d'aquesta tecnologia seria la integració de matrius d'adjacència derivades de les capes d'auto-atenció dels ViTs amb *Graph Neural Networks* (GNNs). Aquesta combinació permetria modelar relacions no trivials entre regions d'imatges i milloraria la precisió en la classificació de malalties com la presència d'infiltracions (lesions pT1) en mostres de teixit de còlon.

2 ESTAT DE L'ART

Els models tradicionals de *Machine learning* (ML) tals com les regressions lineals [10], els arbres de decisió [11], random forests [12]... Presenten una sèrie de limitacions quan intenten tractar amb imatges, per exemple, no aconsegueixen captar les relacions complexes presents en les imatges i normalment careixen d'interpretabilitat i eficiència. [8]

Per superar aquestes limitacions, les xarxes neuronals convolucionals (CNNs) [9] han estat durant anys l'estàndard en el processament d'imatges dins del deep learning. Les CNNs aprofiten filtres convolucionals per extreure patrons locals, com vores i textures, capturant jeràrquicament característiques més complexes a mesura que es profunditza en les seves capes. Aquesta arquitectura ha demostrat un gran èxit en tasques de classificació i segmentació d'imatges biomèdiques, però presenta mancances, a la hora de capturar relacions globals dins de la imatge. S'ha aplicat CNNs a tasques de classificació en *datasets* de histopatologia en càncer colorectal, aconseguint una *accuracy* de 96.98% [7].

Davant de les limitacions dels mètodes tradicionals, els *Vision Transformers* (ViTs) han sorgit com una alternativa

innovadora. A diferència d'altres models, els ViTs divideixen una imatge en petits *patches* i apliquen mecanismes d'auto-atenció per capturar relacions globals entre aquests *patches* [1]. Aquesta arquitectura permet modelar millor les dependències dins d'una imatge, proporcionant un avantatge significatiu en tasques com la classificació d'imatges biomèdiques. Tot i així, els ViTs requereixen grans quantitats de dades per entrenar-se de manera eficient i poden ser computacionalment costosos. En estudis recents, s'ha aplicat l'ús de ViTs en classificació d'imatges histopatològiques de teixits colorectals sans i amb lesions cancerígenes, obtenint resultats molt satisfactoris amb un AUC del 0.941 [4].

L'estat actual de la investigació en aquest camp apunta cap a la combinació d'aquests models amb estructures de graf per millorar-ne la interpretabilitat i l'eficiència [2]. L'ús de xarxes neuronals de graf (GNNs) ha permès representar les relacions entre diferents regions d'una imatge de manera més estructurada, aprofitant les connexions espacials i semàntiques dels teixits biomèdics. Aquestes xarxes processen la informació modelant les imatges com a grafs, on els nodes representen regions d'interès i les arestes indiquen relacions espacials o semàntiques. Això permet capturar interaccions complexes que altres arquitectures poden passar per alt [3]. Tanmateix, el seu entrenament requereix recursos computacionals considerables, tant en termes de temps com de memòria. Requereixen també d'una gran quantitat de dades quan es treballa amb estructures de graf suficientment denses com per classificar imatges.

Normalment, per tal de classificar imatges utilitzant GNNs, s'ha de fer un procés previ a les imatges, per a generar un graf (nodes i arestes) que representi la seva estructura, en aquest cas, del teixit biopsiat. Una possible aproximació seria dividir la imatge en regions, que serien els nodes del graf i extreure aquestes característiques. Normalment això es fa utilitzant una CNN o bé amb tècniques manuals d'extracció (basant-nos en textura, color...).

Aquestes característiques se'ls hi associen a cada node, i seguidament es connecten els nodes per proximitat o similitud, segons la metodologia que triem. Un cop tenim aquest graf (modelat en una matriu d'adjacència), s'entrena una GNN per a que aprengui les relacions complexes d'aquest graf. Finalment, utilitzant una capa d'agregació i una de classificació aconseguim que una GNN ens solucioni un problema de classificació. Un exemple concret de l'aplicació de GNNs en classificació en imatges histopatològiques és l'ús d'aquestes xarxes en imatges de teixits de càncer de pròstata i mama, obtenint una *accuracy* del 94% en tasques de classificació [5].

Les GNNs han evolucionat amb la incorporació de mecanismes d'atenció, fet que ha potenciat encara més la seva capacitat per modelar dades complexes com les relacions espacials en teixits biomèdics o la interacció entre cèl·lules




Figura 1: Esquema general del flux de treball

en imatges histopatològiques. [1] Aquest enfocament es focalitza en les connexions més rellevants dins d'una imatge. A més, els avenços recents han permès la fusió de ViTs amb GNNs en una mateixa arquitectura per combinar la capacitat d'aprenentatge de patrons dels *Transformers* amb la representació estructurada pròpia dels grafs, millorant la capacitat de classificació i detecció de patologies tant a nivell local com global dins d'una imatge biomèdica. [5] Aquestes tècniques estan consolidant un nou paradigma en l'anàlisi d'imatges mèdiques. Quan combinem GNNs amb ViTs, la necessitat de grups grans de dades s'incrementa, ja que per assegurar una bona convergència degut a la complexitat del model, ambdós models requereixen una gran quantitat de dades. A més, en investigacions recents, s'han desenvolupat models híbrids com les *Graph Transformer Networks* (GTNs) aplicats a la representació i classificació de imatges histopatològiques de càncer de pulmó, aconseguint una accuracy de 91.6% i una AUC de 96.7%[6].

3 OBJECTIUS

L'objectiu principal d'aquest treball és l'anàlisi i l'avaluació d'espais de representació profunds amb la finalitat de

millorar la detecció d'infiltracions de carcinoma colorectal pT1 en imatges d'histopatologia.

Objectiu 1: Preparació i anàlisi de la base de dades: Establir mètodes per generar els *patches*, aplicar els filtres corresponents i entendre la distribució de les classes presents a la base de dades.

Objectiu 2: Implementació i entrenament de models de deep learning existents: Entrenar i comparar el rendiment d'una CNN, una ResNet preentrenada, una DenseNet preentrenada, un ViT preentrenat i un ViT preentrenat específicament en histopatologia

Objectiu 3: Desenvolupament d'arquitectures híbrides: Integració de mètodes com ViT + NN o ViT + GNN.

Objectiu 4: Experimentació amb diferents estratègies d'agregació de les matrius d'atenció: Promig de les matrius, agregació de les matrius, ensemble de varis models GAT o GCN utilitzant totes les matrius d'atenció del ViT.

Objectiu 5: Validació de la capacitat de generalització i reproductibilitat: Avaluació dels models desenvolupats tenint en compte si són robustos i aplicables en un entorn clínic real.

4 METODOLOGIA

L'esquema de la figura 1 mostra el flux de treball del projecte. Extracció de característiques i matrius del ViT per fer-les servir com a *input* en diferents arquitectures tradicionals com són una NN, una GAT i una GCN.

4.1 Anàlisi i preprocessament de les dades

Per tal de tractar les imatges amb models de visió per computador i xarxes neuronals, aquestes es divideixen en petits fragments quadrats o patches de 224×224 píxels, utilitzant una estratègia de finestra lliscant amb un paràmetre stride fixa't a 48 píxels que indica la possible superposició. Aquesta divisió es realitza tant sobre la imatge original com sobre la seva màscara associada, que distingeix entre teixit normal i teixit patològic (infiltració tumoral). Els patches generats es conserven tenint en compte una variable que regula la quantitat de teixit que hi ha en la imatge. Si contenen una proporció mínima de teixit (almenys el 75% de la superfície del patch).

A partir de les màscares, es calcula el percentatge d'infiltració tumoral per *patch* i es classifiquen com a malignes o benignes segons si els l·lindars de malignitat (major de 75%) i benignitat (menor de 25%) són superats. Per evitar desequilibris entre classes, es fa una submostra estratègica dels patches 100% patològics. Finalment, es generen les variables d'interès: les imatges, les màscares, les coordenades dels patches dins la imatge original, el percentatge d'infiltració i identificadors relatius al pacient i centre hospitalari.

4.2 Implementació i entrenament de models de deep learning existents

Com a punt de partida, s'ha implementat una xarxa neuronal convolucional (CNN) composta per tres capes convolucionals amb funcions d'activació ReLU, seguides de capes de *max-pooling* per reduir la dimensionalitat espacial. Aquesta arquitectura bàsica finalitza amb una capa *fully connected* per fer la classificació binària. Aquest model ha servit per establir una línia base que permet avaluar la dificultat de la tasca i comparar el rendiment amb arquitectures més sofisticades.

Seguidament, s'ha utilitzat la xarxa ResNet18 [13], una arquitectura residual que facilita l'entrenament de xarxes profundes gràcies a la incorporació de connexions residuals (*skip connections*). El model s'ha adaptat a la nostra tasca substituint la capa de classificació final per una capa *fully connected* amb una única sortida binària i funció d'activació sigmoide, per tal d'ajustar-se a la classificació entre lesions benignes i malignes.

Per una altra banda, s'ha provat l'arquitectura DenseNet121 [14]. DenseNet aprofita connexions denses entre capes, de manera que cada capa rep com a entrada la sortida de totes les capes anteriors, promovent la reutilització de característiques i millorant el flux d'informació. Igual que amb la ResNet, s'ha modificat la darrera capa per adaptar-la a una classificació binària. Aquest model permet estudiar com la major densitat de connexions afecta el rendiment en un context mèdic amb un dataset amb característiques fines i estructures microscòpiques.

Finalment s'ha provat l'arquitectura *Vision Transformer* (ViT) [15] que també ens servirà de base per a les arquitectures híbrides dissenyades.

El ViT és una adaptació de l'arquitectura *Transformer*, originalment desenvolupada per al processament de llenguatge natural (NLP), a l'àmbit de la visió per computador. La idea fonamental consisteix a representar una imatge com una seqüència de vectors, anàloga a les paraules en una frase: cada "paràgraf" de la imatge, determinat per un bloc rectangular de píxels, es converteix en un *token* que el model pot processar.

Inicialment, prenem una imatge d'entrada de dimensions $H \times W$ amb C canals i la dividim en patches quadrats de mida $P \times P$, obtenint $N = (H/P) \cdot (W/P)$ patches. Cada patch s'aplana en un vector de longitud $P^2 \cdot C$ i s'envia a través d'una projecció lineal d'*embedding* capaç de transformar-lo a un espai de dimensions D . D'aquesta manera, la imatge es converteix en una seqüència de N vectors, cadascun en R^D , sent R el conjunt de nombres reals.

Per aportar informació sobre la posició de cada patch s'afegeix a cada *embedding* un vector de posició aprenent que indica la ubicació relativa del *token*. Al principi de la seqüència s'insereix, a més, un *token* especial de classificació, sovint anomenat CLS, que actuarà com a representant global de la imatge durant la classificació final.

La seqüència augmentada amb aquests embeddings es processa a continuació per un *encoder Transformer* format per L capes idèntiques. Cada capa incorpora un mecanisme de *Multi-Head Self-Attention* (MHSA) que calcula, per a cada *token*, tres vectors: Q (*Query*) que expressa la capacitat del *token* per sol·licitar informació a altres tokens, K (*Key*) que codifica les característiques que aquest *token* pot oferir als altres i V (*Value*) que conté la informació efectiva que serà compartida. Mitjançant una atenció escalar, que es calcula fent el producte escalar entre Q i K per determinar en quina quantitat un *token* respon a un altre i finalment aplicant aquesta ponderació a V per sumar la informació rellevant de tots els *tokens*, cada *token* pondera la relació amb tots els altres de la seqüència, capturant així dependències globalitzades. A continuació, el resultat es combina amb el vector d'entrada mitjançant una connexió residual i s'aplica una normalització.




Figura 2: Esquema de funcionament intern d'un ViT

Després de l'atenció, un bloc MLP complementari processa cada token de manera independent amb dues capes lineals separades, seguint novament l'esquema de residual i normalització. Aquest doble pas d'atenció global i transformació local es repeteix L (nombre de capes del ViT) vegades, obtenint-se finalment una seqüència de representacions que integren informació local i de llarga distància.

El pas definitiu consisteix a extreure el *token* CLS de l'última capa, que conté la informació agregada de tots els *patches*, i projectar-lo mitjançant una capa lineal cap al nombre de classes desitjat. Un softmax final converteix aquestes puntuacions en probabilitats de classificació. (Vegeu annex A2 per un esquema)

Aquesta arquitectura s'ha implementat tant sent preentrenada en el *dataset* ImageNet que és una base de dades massiva d'imatges etiquetades, composta per més de 14 milions d'imatges agrupades en mil categories diferents (com ara gats, avions, flors o rellotges) com sent preentrenada en un dataset únicament d'imatges d'histopatologia.

4.3 Disseny i implementació de les arquitectures híbrides

El següent pas ha sigut combinar la extracció de característiques del ViT amb diferents models. El ViT proporciona un vector de característiques i 12 matrius que representen les atencions entre patches.

El primer enfocament ha sigut passar el CLS extret de les imatges a una NN. En aquest cas, el ViT aprofita la seva capacitat per capturar relacions espacials globals, mentre que la NN processa aquestes representacions per aprendre

patrons locals addicionals. Aquesta arquitectura permet combinar la potència de representació del ViT amb la senzillesa i eficiència de les NNs. S'han provat dos tipus de NNs, primer una capa lineal *fully Connected* i després una petita arquitectura, que consta d'una capa lineal, una capa ReLU, una capa *drop-out* i finalment una capa *fully connected* per a binaritzar la classificació.

Seguidament, i sabent que el ViT representa les atencions entre patches com unes matrius, s'ha pensat en fer servir xarxes neuronals basades en grafs (GNN)[17].

Les GNNs són una família de models de deep learning dissenyades per a treballar amb dades estructurades en forma de graf. En un graf tenim un conjunt de vèrtexs (*nodes*) i arestes (*edges*) que connecten parelles de vèrtexs. Les GNNs aprofiten aquest tipus d'estructura per aprendre representacions que tenen en compte tant les característiques dels nodes com la topologia general del graf.

Les GNNs aplicades a classificació generalment segueixen un esquema de propagació de missatges que consisteix de 3 passos.

Sabent que cada node v té un vector de característiques inicial $h_v^{(0)}$:

El primer pas és la agregació de missatges. En la capa l , cada node recull informació dels seus veïns $u \in N(v)$:

$$m_v^{(l)} = \text{AGGREGATE}^{(l)} \left(\{h_u^{(l-1)} : u \in N(v)\} \right)$$

El segon pas és la actualització on el node combina el seu estat anterior amb el missatge agregat:

$$h_v^{(l)} = UPDATE^{(l)}(h_v^{(l-1)}, m_v^{(l)})$$

L'últim pas és el readout, on es calcula una representació global del graf agregant tots els $h_v^{(l)}$.

Fent servir aquest procés la informació flueix a través del graf i fa que cada node aprengui representacions basades en el seu entorn local i global.

Per a la nostra tasca, hem fet servir dos tipus concrets de GNNs, les *Graph Convolutional Networks* (GCN)[16] i les *Graph Attention Networks* (GAT) [2].

Les GCN són el tipus més popular de GNN. Extreuen informació dels veïns mitjançant una operació de convolució definida sobre el graf.

En les GCN, a cada capa l , l'actualització per a cada node v és:

$$h_v^{(l)} = \sigma \left(\sum_{u \in N(v) \cup \{v\}} \frac{1}{\sqrt{\deg(v)\deg(u)}} W^{(l)} h_u^{(l-1)} \right)$$

On $\deg(v)$ és el nombre de veïns de v , $\deg(u)$ és el nombre de veïns de u , $W^{(l)}$ són pesos que la xarxa pot aprendre i σ és la funció d'activació, que en el nostre cas és ReLU.

Les GAT incorporen mecanismes d'atenció per ponderar de manera més flexible la contribució de cada veí. Un mecanisme d'atenció és una manera de representar quant relacionats estan dos patches en la imatge, en el nostre cas. Per calcular-ho ho fan de la següent forma:

Per a cada aresta (v, u) a la capa l , primer calcula una puntuació no normalitzada:

$$e_{vu}^{(l)} = LeakyReLU(a^{(l)T} [W^{(l)} h_v^{(l-1)} || W^{(l)} h_u^{(l-1)}])$$

On $a^{(l)}$ són paràmetres que el model pot aprendre i $||$ indica concatenació.

Seguidament es normalitza utilitzant softmax sobre els veïns de v :

$$\alpha_{vu}^{(l)} = \frac{\exp(e_{vu}^{(l)})}{\sum_{k \in N(v)} \exp(e_{vk}^{(l)})}$$

Finalment actualitza:

$$h_v^{(l)} = \sigma \left(\sum_{u \in N(v)} \alpha_{vu}^{(l)} W^{(l)} h_u^{(l-1)} \right)$$

Així doncs combinant la capacitat d'extreure característiques del ViT amb la capacitat per entendre-les de les GNNs, potser aconseguim un model que pot entendre tant característiques locals com globals.

Cal recalcar també que tan GCN com GAT es poden alimentar de grafos amb pesos o sense i que per aconseguir això es binaritza a partir d'un llindar, th_bin . Aquest th_bin s'utilitza per binaritzar o per considerar pesos per sobre aquesta quantitat.

En les GCN, aquests pesos s'incorporen modificant la matriu d'adjacència ponderada, i afecten tant la normalització com l'agregació:

$$h_v^{(l)} = \sigma \left(\sum_{u \in N(v) \cup \{v\}} \frac{edgeW_{vu}}{\sqrt{\deg(v)\deg(u)}} W^{(l)} h_u^{(l-1)} \right)$$

On $edgeW_{vu}$ son els pesos que extreiem de les matrius.

En el cas de les GAT, aquests pesos poden substituir directament els pesos d'atenció apresos $\alpha_{vu}^{(l)}$, o bé combinar-s'hi. Això permet guiar multiplicant els pesos que conté la matriu amb els pesos que pot aprendre la xarxa:

$$h_v^{(l)} = \sigma \left(\sum_{u \in N(v)} edgeW_{vu} \tilde{\alpha}_{vu}^{(l)} W^{(l)} h_u^{(l-1)} \right)$$

On $edgeW_{vu}$ son els pesos que treiem de la matriu d'atenció extreta del ViT. Aquests pesos, a part de guiar també poden inicialitzar els primers pesos des d'on parteix l'entrenament de la GAT, fent $\tilde{\alpha}_{vu}^{(l)} = edgeW$, en comptes de multiplicar-los.

Aquestes puntuacions tenen valors gairebé insignificants (entre 0 i 1), i per tal d'amplificar el seu valor apliquem una petita transformació.

$$nouPes = \exp(pes * 10)$$

4.4 Estratègies d'agregació:

Com aquestes xarxes neuronals només accepten una matriu com a entrada per tal de representar un graf, s'han implementat diverses maneres d'introduir les 12 matrius a la GNN.

La primera modalitat consisteix en fer una mitjana ponderada de les 12 matrius per a extreure'n una que conté tota la informació de totes les matrius, en la taula de resultats representada per (M). En la segona modalitat s'ha afegit una capa d'agregació Conv2D als models per a poder també entrenar la manera en què s'agreguen aquestes matrius, representat per (A) en la taula de resultats. Aquesta capa aplica filtres per fer una agregació ponderada de la matriu. En la última s'han entrenat 12 models, un per cada matriu, per al final predir utilitzant aquests 12 models, fent servir la estratègia d'ensemble maxVoting (la classe més votada és la predicció final del ensemble) [18]. En la taula de resultats representat per (E).

5 BASE DE DADES

Les dades utilitzades en aquest estudi consisteixen en

imatges histopatològiques provinents de diversos centres hospitalaris, incloent-hi hospitals com Terrassa, Manresa, Basurto, Bellvitge i Alicante. Aquesta diversitat d'origen implica una major variabilitat en les dades, fet que enriqueix la robustesa del model però alhora planteja reptes addicionals pel que fa al preprocessament i l'estandardització.

Per tal de tindre més coneixença de les dades que tenim en el nostre dataset, s'ha fet un *Exploratory Data Analysis* (EDA) (Vegueu annex A1).

Aquest anàlisi ens mostra un balanceig casi perfecte en el conjunt de train amb un petit predomini de la classe benigna (1220 mostres malignes respecte 1444 benignes). Això pot conduir a biaixos en el moment d'entrenament i validació creuada.

Els patches del train provenen de diversos pacients, la qual cosa proporciona una mostra més diversa i rica en variabilitat. Pel que fa al percentatge d'infiltració tumoral també s'observa un patró divergent ja que en el train els valors tendeixen a concentrar-se al voltant del valor màxim (1) indicant una alta presència de tumor.

Aquesta diferència entre distribucions tant en les etiquetes com en les característiques clíniques suggereix un desajust entre les dos classes que cal tenir en compte durant el desenvolupament del model aplicant si cal tècniques específiques com afegir pesos a la funció de pèrdua, l'augmentació de dades o estratègies de validació més robustes que ajudin a minimitzar els efectes d'aquest desbalanceig.

6 EXPERIMENTS I RESULTATS

6.1 Mètriques per comparar models

Per avaluar el rendiment dels models de classificació, s'han utilitzat diverses mètriques que permeten analitzar tant el comportament global com el rendiment específic per a cada classe (benigne i maligne). Les mètriques computades són:

- **AUC** (*Area Under the ROC Curve*): mesura la capacitat del model per diferenciar entre classes. Un AUC proper a 1 indica una separació eficaç entre les classes benigna i maligna.
- **Recall** (Sensibilitat): indica la proporció de casos reals detectats correctament pel model. Es calcula per a cada classe.
- **Precision** (Precisió): quantifica la proporció de prediccions correctes dins de les prediccions positives fetes pel model, també per classe.
- **F1-score**: és la mitjana entre la precisió i el recall. Aquesta mètrica és útil especialment en casos amb desequilibri de classes i també s'ha computat per separat per a cada classe.

A més de les mètriques numèriques, també s'han utilitzat

eines de visualització per facilitar la comparació entre models:

- **Corbes ROC**: representen la relació entre el *True Positive Rate* i el *False Positive Rate* a diferents llindars de classificació. Són útils per visualitzar el comportament global del model.
- **Gràfiques de *training loss***: mostren l'evolució d'aprenentatge durant l'entrenament, per cada fold. Aquestes corbes permeten detectar problemes com el overfitting. (Annex A4)

6.2 Validació i entorn d'implementació

Per garantir la robustesa i la validesa dels resultats, s'ha utilitzat un esquema de validació creuada estratificada (StratifiedGroupKFold) amb grups (pacients). S'ha fet la validació amb els paràmetres $k=5$ i 2664 mostres. Aquest enfocament assegura que totes les imatges d'un mateix pacient es mantenen dins d'un mateix grup, evitant que una mateixa font d'informació aparegui tant en entrenament com en validació.

A més, s'ha separat un conjunt hold-out de 359 mostres que no participa en cap fold de validació i s'utilitza exclusivament per avaluar el rendiment final del model. Aquestes mostres provenen d'un hospital diferent de les mostres del conjunt de train, fet que simula una situació real, proporcionant una estimació de la capacitat de generalització del sistema.

Els experiments s'han implementat en Python (3.8.10) i executat sobre un cluster amb 8 GPUs NVIDIA GeForce i 512 GB de memòria RAM per accelerar el procés d'entrenament. L'entorn inclou les següents biblioteques principals:

- PyTorch (2.4.1+cu121) i PyTorch Geometric (2.6.1) per a la definició i entrenament de models, incloent-hi GNNs.
- HuggingFace Transformers per a la càrrega de models preentrenats com ViT.
- Scikit-learn per al càlcul de mètriques i gestió dels esquemes de validació.
- Matplotlib per generar les gràfiques de pèrdua i corbes ROC.
- PIL per al processament de les imatges.

6.3 Experiments

En aquesta secció es presenten tres experiments principals per validar i analitzar el rendiment dels models desenvolupats. El primer experiment compara arquitectures tradicionals de *deep learning* amb models híbrids. El segon experiment analitza diferents estratègies per agregar la informació de les matrius d'atenció d'un ViT i com això afecta el rendiment dels models GNN. Finalment, el tercer experiment proporciona una validació estadística de les diferències observades entre models mitjançant intervals de confiança i t-tests aparellats sobre mètriques rellevants

com l'AUC i el recall.

Exp1: Comparació entre models tradicionals i models híbrids

L'objectiu d'aquest experiment és comparar models "tradicionals", basats únicament en informació dels píxels de la imatge (com una CNN), amb models híbrids que incorporen una representació estructurada mitjançant grafs que surten de les matrius d'atenció d'un ViT i processats per una GNN. Totes les arquitectures han estat entrenades des de zero, excepte el ViT al qual se li ha fet un *finetuning* degut a la falta de dades.

En aquest experiment entrenem i avaluem una CNN, una ResNet, una DenseNet, un ViT de Google, un ViT entrenat sobre imatges d'histopatologia i les comparem amb les arquitectures híbrides ViT+NN i ViT+GNN.

Exp2: Comparació entre mètodes d'agregació de les matrius

Aquest experiment compara les diferents estratègies per combinar les 12 matrius de self-attention del ViT (Mitjana, agregació entrenada i ensemble amb *maxVoting*) i passar les matrius a les arquitectures GNN (GAT i GCN).

Exp3: Validació estadística dels millors models

Als millors models se'ls hi ha fet un experiment estadístic per saber quanta confiança s'hi pot posar en ells. Primerament s'ha calculat el *Confidence Interval* [20] de les mètriques escollides (AUC, Recall Benigne i Recall maligne), per donar-nos un rang dins del qual esperar que està el valor real de la mitjana d'una població amb un 95% de confiança.

$$CI = \bar{x} \pm t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}}$$

On $\bar{x}$ és la mitjana dels valors escollits, s la desviació estàndard, n nombre de folds dels que fem el CI i $t_{\alpha/2, n-1}$ és el valor crític de la distribució t amb 4 graus de llibertat.

Després s'ha fet un t-test per a mostres aparellades [20] per comparar si les diferències observades entre els models i el millor model són estadísticament significatives, és a dir, si es poden atribuir realment a un millor rendiment d'un model respecte a l'altre o bé si podrien haver sorgit per atzar.

$$t = \frac{\bar{d}}{\frac{s_d}{\sqrt{n}}}$$

On $\bar{d}$ és la mitjana de les diferències, s_d la desviació estàndard de les diferències i n el nombre de parelles.

El test ha estat aplicat sobre la AUC, el recall benigne i el recall maligne de cada fold. S'han escollit aquestes mètriques per a la validació estadística perquè són les mètriques més rellevants en diagnòstic digital, ja que la AUC

representa el compromís entre recall i precisió i el recall representa com de bé el sistema detecta si el teixit és benigne o maligne.

Amb aquest test s'ha obtingut un p-value per cada comparació, que indica la probabilitat de trobar una diferència igual o més extrema que l'observada si en realitat no hi hagués cap diferència entre models. Si aquest valor és inferior a un llindar (0.05), es pot rebutjar la hipòtesi nul·la i concloure que la diferència entre models és estadísticament significativa.

6.4 Resultats:

La taula completa dels resultats es troba en els annexos, en la taula 3 (annex A4). En la primera fila de la taula trobem totes les mètriques que hem utilitzat per a avaluar els experiments i en la primera columna podem trobar els models amb els que hem experimentat. Les mètriques que hem fet servir (d'esquerra a dreta) són AUC, que és el compromís entre recall i precisió, recall benigne i maligne que ens diu com de bo és el sistema detectant les diferents classes, precisió benigna i maligna que mostra com de bo és el sistema no equivocant-se amb la classe i la f1-score benigna i maligna que és la mitjana harmònica del *precision* i el *recall*. S'han seleccionat aquestes mètriques perquè ens proporcionen un estudi precís del rendiment del model desde diferents punts de vista.

En les 5 primeres files trobem les arquitectures tradicionals, de les quals la millor és la ResNet amb una AUC de 0.9279, això segurament és degut a les *skip connections* que caracteritzen aquest model i que permeten generalitzar millor. En les dos següents files apareixen les primeres arquitectures híbrides, ViT+NN linear i ViT+NN Arq. linear significa que la NN només consisteix d'una capa fully connected que serveix per a classificar i Arq significa que hi ha una arquitectura a darrere, que consta de una capa linear, una capa ReLU, una capa drop-out i finalment una **capa** fully connected per a binaritzar la classificació. En aquestes files apareix el millor model, ViT+NN linear, amb una AUC de 0.9537. Les últimes columnes ensenyen les arquitectures híbrides ViT+GNN, amb les seves diferents tècniques d'agregació (M: Mitjana, A: Agregació entrenada, E: Ensemble) i segons si s'han entrenat fent servir els pesos de la matriu d'atenció o si simplement s'ha binaritzat la matriu (P: Entrenament amb pesos, NP: Entrenament sense pesos). El millor model GAT d'aquest apartat és el ViTGAT amb agregació entrenada i fent servir els pesos amb una AUC de 0.9411, i el millor model GCN d'aquest apartat és el ViTGCN amb ensemble sense pesos amb una AUC de 0.9279.

En la taula 1 podem veure els models de cada experiment que millor han respost al problema. Aquests són la ResNet, el ViT+NN Linear, ViT+GAT agregat amb pesos i ViT+GCN agregat sense pesos.

A/M	ResNet	ViTNNL	ViT-GAT(A) P	ViT-GCN(A) NP
AUC	0.9279 ± 0.0451	0.9537 ± 0.0771	0.9411 ± 0.0415	0.9238 ± 0.0441
RB	0.8222 ± 0.1058	0.8989 ± 0.1070	0.7523 ± 0.1011	0.7963 ± 0.1212
RMa	0.8753 ± 0.0665	0.9346 ± 0.0538	0.9530 ± 0.0235	0.9054 ± 0.0488
PB	0.8990 ± 0.0424	0.9461 ± 0.0410	0.9516 ± 0.0156	0.9161 ± 0.0155
PMa	0.8110 ± 0.1043	0.8875 ± 0.1212	0.7738 ± 0.0767	0.8110 ± 0.0926
F1-B	0.8528 ± 0.0514	0.9194 ± 0.0724	0.8366 ± 0.0647	0.8468 ± 0.0692
F1-Ma	0.8359 ± 0.0608	0.9072 ± 0.0848	0.8515 ± 0.0488	0.8509 ± 0.0478

Taula 1: Resultats de les mètriques dels millors models (AUC: Area Under Curve, RB: Recall Benigne, RM: Recall Maligne, PB: Precision Benigna, PM: Precision Maligna, F1-B: F1-Score Benigna, F1-M: F1-Score Maligna)

En negreta, tant a la taula 1 com a la 3 hi han les millors puntuacions de cada mètrica. Cal recalcar el 1 de recall benigne de la DenseNet, que tot i ser una puntuació tan alta és desestima ja que la part maligna és de 0 i això significa que només prediu benigne. El millor model ha sigut ViT+NN Linear amb una AUC de 0.9537, però cal destacar el recall maligne i la precisió benigna del ViT+GAT que ens diu que és gairebé perfecte encertant les mostres malignes i que s'equivoca poc quan prediu mostres benignes.

Aquestes 4 arquitectures han estat provades en el conjunt de holdout, però degut als alts resultats (de l'ordre de AUC=0.99), s'han desestimat, ja que ens ha fet pensar que les imatges del hospital de holdout contenen alguna característica que esbiaixa els resultats.

A la taula 2 es poden observar els resultats del experiment de la validació estadística. En la primera fila veiem els millors models. Es mostra, per cada model, el interval de confiança de la mètrica esmentada en la mateixa fila, juntament amb el *p-value* resultant d'aplicar un t-test de la mètrica que precedeix a la fila de p-val. Recalcar que si el *p-value* no supera 0.05 significa que hi ha una diferència estadísticament significativa entre dos models.

A/M	ViTNNL	ResNet	ViT-GAT(A)	ViTGCN(A)
AUC	[0.8862, 0.9297]	[0.8501, 0.9872]	[0.8835, 0.9987]	[0.8626, 0.9851]
p-val	---	0.0782	0.5729	0.4397
RB	[0.7846, 0.8657]	[0.7048, 0.8872]	[0.6119, 0.8926]	[0.6280, 0.9646]
p-val	---	0.0901	0.0329	0.1788
RM	[0.8823, 0.9207]	[0.8403, 0.9411]	[0.9203, 0.9857]	[0.8377, 0.9732]
p-val	---	0.0495	0.3587	0.3251

Taula 2: Resultats de la validació estadística dels millors models

En la figura 3 podem veure les corbes ROC dels 4 models, per poder tindre una referència visual de com funcionen els models.




Figura 3: Corbes ROC corresponents als millors model

Els resultats obtinguts mostren que el model ViT+NNL presenta el millor rendiment global en totes les mètriques avaluades, destacant especialment en AUC, amb una mitjana de 0.9537. Tant les arquitectures híbrides ViT+GAT com ViT+GCN presenten valors mitjans similars, però els t-test realitzats mostren que les diferències no són estadísticament significatives ($p > 0.05$) en la majoria de mètriques, com l'AUC i el recall maligne. L'única excepció és el recall benigne per ViTGAT(A), on s'observa una diferència significativa ($p = 0.0329$) respecte a ViTNNL, indicant una possible debilitat d'aquest model en aquest aspecte específic.

D'altra banda, el model ResNet mostra un rendiment inferior de manera consistent donats els p-valors propers al llindar 0.05 que suggereixen una diferencia significativa. Les comparacions estadístiques amb ViTNNL mostren la superioritat del model basat en ViTs.

Finalment, les corbes ROC de la figura 3 segueixen mostrant la superioritat del model ViT+NNL demostrant una alta capacitat de discriminació entre classes, tanmateix, les altres arquitectures segueixen assolint resultats molt competius. Cal destacar també que els models basats en graf son els models amb menor desviació estàndard, demostrant una major estabilitat entre folds.

7 CONCLUSIÓ I DISCUSSIÓ

L'objectiu inicial del projecte era explorar com els ViTs podien complementar-se amb GNNs per millorar la classificació en imatge mèdica histopatològica mitjançant l'atenció del ViT per tal de donar una representació a la nostra imatge, no fent servir el preprocessament típic que es fa en aquests casos. La hipòtesi plantejava que, aprofitant les capacitats d'atenció de ViT i atenció estructural de les GNNs, es podria obtenir el millor rendiment en un entorn clínic amb dades complexes. Tanmateix, els resultats obtinguts no diuen el mateix, ja que confirmen que la millor arquitectura és la combinació entre ViTs i NNs. Això és degut a

que en la linear s'utilitza el CLS que es el resum global de la estructura d'atenció i això sembla que tingui més capacitat de generalització i representació.

Tot i així, els resultats suggereixen que usar els Vision Transformers com a extractors de característiques per construir arquitectures híbrides és una bona decisió. Mostren que l'atenció apresada pel ViT ja conté relacions prou riques, i afegir una segona capa d'atenció, tot i que també dona unes puntuacions altes, no pot amb la capacitat de generalització d'una NN. També podem comprovar que el canvi en la manera d'agregar les matrius només suposa un canvi en els ensembles i de totes maneres, és desestimable degut a la gran complexitat computacional que suposa executar aquest model. També s'observa que afegir pesos o no a les arquitectures basades en grafs no dona una millora significativa en els resultats.

En conclusió, si bé la combinació ViT+NN demostra ser la més potent en aquest context, les arquitectures híbrides amb GNN també són altament competitives i ofereixen una via prometedora per capturar tant relacions espacials com semàntiques en dades d'imatge mèdica. A més, aquest estudi obre la porta a futures línies de recerca que explorin mètodes d'agregació més sofisticats o estratègies d'entrenament conjunts per maximitzar la sinergia entre ViTs i GNNs.

Com a treball futur, es planteja desenvolupar un anàlisi més profund de l'explicabilitat dels models mitjançant l'ús de heatmaps que permetin visualitzar les regions d'interès i comprendre millor les decisions preses pels models híbrids.

A més, es preveu una experimentació més extensa amb la ponderació dels pesos de les matrius per optimitzar el rendiment i la interpretabilitat. També es preveu aplicar la mateixa metodologia híbrida però partint d'un model preentrenat (UNI2)[21] en imatges d'histopatologia. Finalment, seria interessant validar l'enfocament en un dataset més gran i divers per assegurar la robustesa i generalització dels resultats obtinguts.

8 AGRAIMENTS

Per últim, vull expressar el meu sincer agraïment a Carles Sánchez, tutor del treball, per la seva constant dedicació, pels seus consells i per haver-me guiat i ajudat en tot moment durant el desenvolupament i seguiment del projecte. Agraïxo també al Centre de Visió per Computador (CVC), en concret al grup Interactive Augmented Modelling (IAM) per proporcionar les dades necessàries i l'accés al clúster de càlcul, essencial per a l'execució dels models. Vull donar les gràcies també als Hospitals de Terrassa, Manresa, Basurto, Bellvitge i Alacant per la seva col·laboració mitjançant la cessió de dades que han estat clau per dur a terme aquesta recerca. Finalment a la meua parella Jana Camps Teixidó i als meus amics i Companys per donar tot el suport emocional que un pot demanar.

Bibliografia

- [1] Shehzad, A., Xia, F., Abid, S., Peng, C., Yu, S., Zhang, D., & Verspoor, K. (2024). Graph transformers: A survey. *arXiv preprint arXiv:2407.09777*.
- [2] SUN, Chengcheng, et al. Attention-based graph neural networks: a survey. *Artificial intelligence review*, 2023, vol. 56, no Suppl 2, p. 2263-2310.LU,
- [3] Zekun, et al. Learning weight signed network embedding with graph neural networks. *Data Science and Engineering*, 2023, vol. 8, no 1, p. 36-46
- [4] Chen, R. J., & Krishnan, R. G. (2022). Self-supervised vision transformers learn visual concepts in histopathology. *arXiv preprint arXiv:2203.00585*.
- [5] Sureka, M., Patil, A., Anand, D., & Sethi, A. (2020, October). Visualization for histopathology images using graph convolutional neural networks. In *2020 IEEE 20th international conference on bioinformatics and bioengineering (BIBE)* (pp. 331-335). IEEE.
- [6] Shi, Z., Zhang, J., Kong, J., & Wang, F. (2024, October). Integrative Graph-Transformer Framework for Histopathology Whole Slide Image Representation and Classification. In *International Conference on Medical Image Computing and Computer-Assisted Intervention* (pp. 341-350). Cham: Springer Nature Switzerland.
- [7] Ben Hamida A, Devanne M, Weber J, Truntzer C, Derangère V, Ghiringhelli F, Forestier G, Wemmer C. Deep learning for colon cancer histopathological images analysis. *Comput Biol Med*. 2021 Sep;136:104730. doi: 10.1016/j.compbio.2021.104730. Epub 2021 Aug 4. PMID: 34375901.
- [8] Hu, W., Chen, H., Liu, W., Li, X., Sun, H., Huang, X., ... & Li, C. (2022). A comparative study of gastric histopathology sub-size image classification: From linear regression to visual transformer. *Frontiers in Medicine*, 9, 1072109.
- [9] O'shea, K., & Nash, R. (2015). An introduction to convolutional neural networks. *arXiv preprint arXiv:1511.08458*.
- [10] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to linear regression analysis*. John Wiley & Sons.
- [11] Kingsford, C., & Salzberg, S. L. (2008). What are decision trees?. *Nature biotechnology*, 26(9), 1011-1013.
- [12] Rigatti, S. J. (2017). Random forest. *Journal of Insurance Medicine*, 47(1), 31-39.
- [13] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).
- [14] Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 4700-4708).
- [15] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., ... & Housby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*.
- [16] Kipf, T. N., & Welling, M. (2016). Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*.
- [17] Zhou, J., Cui, G., Hu, S., Zhang, Z., Yang, C., Liu, Z., ... & Sun, M. (2020). Graph neural networks: A review of methods and applications. *AI open*, 1, 57-81.
- [18] Hossain, M. M., Hossain, M. M., Arefin, M. B., Akhtar, F., & Blake, J. (2023). Combining state-of-the-art pre-trained deep learning models: A noble approach for skin cancer detection using max voting ensemble. *Diagnostics*, 14(1), 89.
- [19] Mármol, I., Sánchez-de-Diego, C., Pradilla Dieste, A., Cerrada, E., & Rodríguez Yoldi, M. J. (2017). Colorectal carcinoma: a general overview and future perspectives in colorectal cancer. *International journal of molecular sciences*, 18(1), 197.
- [20] Moore, D. S., McCabe, G. P., & Craig, B. A. (2017). *Introduction to the Practice of Statistics* (9th ed.). W.H. Freeman.
- [21] Chen, R.J., Ding, T., Lu, M.Y., Williamson, D.F.K., et al. Towards a general-purpose foundation model for computational pathology. *Nat Med* (2024). <https://doi.org/10.1038/s41591-024-02857-3>

APÈNDIX

A1. IMATGES EXPLORATORY DATA ANALYSIS:




Figura 4: Esquema de distribució de classes de les dades




Figura 5: Histograma de la distribució del percentatge d'infiltració




Figura 6: Gràfic de la distribució de patches per pacient




Figura 7: Mostra random amb la seva màscara (Gris: Benigne, Blanc: Maligne, Negre: Background)

A2. ESQUEMA VISION TRANSFORMER:




Figura 8: Esquema detallat del funcionament d'un Vision Transformer

A3. GRÀFICA DE LOSS




Figura 9: Gràfica de loss de la arquitectura ResNet

A4. Taula completa de resultats

Arq/Mè- trica	AUC		RB		RM		PB		PM		F1-B		F1-M	
CNN	0.7011	± 0.0692	0.7492	± 0.2008	0.4100	± 0.1918	0.6155	± 0.0768	0.4778	± 0.1594	0.6273	± 0.0928	0.3809	± 0.1222
ResNet	0.9279	± 0.0441	0.8222	± 0.1058	0.8753	± 0.0665	0.8990	± 0.0424	0.8110	± 0.1043	0.8528	± 0.0514	0.8359	± 0.0608
DenseNet	0.4996	± 0.0009	1.0000	± 0.0000	0.0000	± 0.0000	0.5423	± 0.0691	0.0000	± 0.0000	0.7006	± 0.0602	0.0000	± 0.0000
ViT	0.9113	± 0.0593	0.8242	± 0.1026	0.8876	± 0.0493	0.8970	± 0.0425	0.7948	± 0.0917	0.8438	± 0.0582	0.8361	± 0.0637
ViT trans- path	0.7594	± 0.0742	0.7459	± 0.2131	0.7730	± 0.1734	0.8315	± 0.0933	0.7622	± 0.1250	0.7547	± 0.1430	0.7453	± 0.0869
ViTNNLin	0.9537	± 0.0771	0.8989	± 0.1070	0.9346	± 0.0538	0.9461	± 0.0410	0.8875	± 0.1212	0.9194	± 0.0724	0.9072	± 0.0848
ViTNNArq	0.8286	± 0.0460	0.7633	± 0.0968	0.8939	± 0.0742	0.9057	± 0.0505	0.7679	± 0.0702	0.8232	± 0.0597	0.8233	± 0.0553
ViTGAT (M) P	0.9000	± 0.0696	0.7385	± 0.1056	0.9469	± 0.0305	0.9473	± 0.0290	0.7581	± 0.0916	0.8253	± 0.0668	0.8390	± 0.0613
ViTGAT (A) P	0.9411	± 0.0415	0.7523	± 0.1011	0.9530	± 0.0235	0.9516	± 0.0156	0.7738	± 0.0767	0.8366	± 0.0647	0.8515	± 0.0488
ViTGAT (E) P	0.9353	± 0.0427	0.7774	± 0.0885	0.9450	± 0.0249	0.9468	± 0.0167	0.7874	± 0.0768	0.8513	± 0.0573	0.8573	± 0.0538
ViTGAT (M)	0.9233	± 0.0404	0.8031	± 0.1257	0.8915	± 0.0887	0.9162	± 0.0545	0.8162	± 0.1089	0.8476	± 0.0622	0.8430	± 0.0565
ViTGAT (A)	0.9000	± 0.0531	0.7779	± 0.1079	0.9096	± 0.0551	0.9190	± 0.0439	0.7863	± 0.0865	0.8365	± 0.0582	0.8389	± 0.0507
ViTGAT (E)	0.9340	± 0.0349	0.7632	± 0.1103	0.9384	± 0.0253	0.9400	± 0.0188	0.7806	± 0.0834	0.8381	± 0.0698	0.8498	± 0.0555
ViTGCN (M) P	0.9115	± 0.0265	0.7406	± 0.0560	0.9091	± 0.0567	0.9095	± 0.0439	0.7463	± 0.0639	0.8157	± 0.0474	0.8191	± 0.0586
ViTGCN (A) P	0.9148	± 0.0288	0.7399	± 0.0722	0.9431	± 0.0271	0.9448	± 0.0249	0.7542	± 0.0757	0.8275	± 0.0421	0.8363	± 0.0518
ViTGCN (E) P	0.9367	± 0.0387	0.7832	± 0.0904	0.9358	± 0.0250	0.9379	± 0.0161	0.7911	± 0.0727	0.8510	± 0.0577	0.8558	± 0.0496
ViTGCN (M)	0.9076	± 0.0542	0.7095	± 0.1513	0.9435	± 0.0606	0.9534	± 0.0340	0.7538	± 0.0996	0.8017	± 0.0882	0.8313	± 0.0529
ViTGCN (A)	0.9238	± 0.0441	0.7963	± 0.1212	0.9054	± 0.0488	0.9161	± 0.0155	0.8110	± 0.0926	0.8468	± 0.0692	0.8509	± 0.0478
ViTGCN (E)	0.9279	± 0.0359	0.7745	± 0.0894	0.9393	± 0.0234	0.9395	± 0.0204	0.7845	± 0.0760	0.8466	± 0.0585	0.8532	± 0.0524

Taula 3: Comparació completa de rendiments entre les arquitectures implementades